

RAPPORT DE BENCHMARKING DES LLM

Projet : Chatbot d'Assistance Juridique — Architecture RAG

Droit du Travail & OHADA · PME

Rédigé par : Mohamed Lamine Niang | Juin 2026

1. Fonctionnement global d'un LLM

1.1 La tokenisation

Un LLM ne traite pas directement du texte brut. Avant tout raisonnement, le texte est découpé en **tokens**, c'est-à-dire des unités élémentaires (mots, sous-mots ou caractères) associées chacune à un identifiant numérique. En français, un mot courant correspond approximativement à 1 à 2 tokens. Ce découpage est réalisé par un **tokenizer** (ex. : BPE — Byte-Pair Encoding, utilisé par Mistral) qui construit un vocabulaire partagé entre l'entraînement et l'inférence.

Exemple : « *contrat de travail* » → [con / trat / de / tra / vail] soit 5 tokens. La qualité du tokenizer pour le français influe directement sur la précision du modèle lors de l'analyse de clauses juridiques.

1.2 La fenêtre de contexte

Chaque requête envoyée au LLM doit tenir dans sa **fenêtre de contexte** (context window), exprimée en tokens. Elle englobe : le document récupéré par le module RAG, l'historique de la conversation et la réponse générée. Dans notre projet, les chunks de documents juridiques (Code du travail, Actes OHADA) consomment une part importante de ce contexte. Un modèle avec une grande fenêtre peut ingérer un article de loi entier ; un modèle contraint devra se limiter à des extraits.

1.3 Génération et mécanisme d'attention

Le LLM prédit le token suivant de manière auto-régressive grâce au mécanisme d'**attention multi-têtes** (Transformer). Il pondère l'importance de chaque token du contexte pour produire une réponse cohérente. Dans un pipeline RAG, le prompt contient les passages juridiques pertinents récupérés depuis la base vectorielle ; le LLM les lit, les reformule et répond à la question de l'utilisateur en respectant le texte de référence, limitant ainsi les hallucinations.

2. Présentation des modèles choisis

Quatre modèles ont été retenus pour l'analyse, représentatifs des deux grandes familles (propriétaire et open-source) et pertinents pour le traitement du français juridique.

mistral-small-latest (Mistral AI — France)

Modèle retenu pour le projet. Développé à Paris par Mistral AI et accessible via l'API officielle Mistral sous l'identifiant *mistral-small-latest*, ce modèle est entraîné sur un corpus multilingue à forte représentation du français. Sa fenêtre de contexte de 32 000 tokens est amplement suffisante pour nos chunks juridiques. Hébergé sur l'infrastructure européenne de Mistral AI, il garantit une conformité RGPD satisfaisante pour les PME. Son coût API est de 0,20 \$ pour 1 million de tokens en entrée — soit 25 fois moins cher que GPT-4o.

Gemini 1.5 Pro (Google DeepMind)

Modèle propriétaire de Google disposant d'une fenêtre de contexte record d'un million de tokens, ce qui lui permettrait théoriquement d'ingérer un code du travail complet en une seule requête. Sa maîtrise du français est très bonne. Cependant, le coût API (3,50 \$ / 1M tokens en entrée) et l'absence de déploiement local en font une option plus coûteuse et moins adaptée aux contraintes de souveraineté des données.

GPT-4o (OpenAI)

Modèle phare d'OpenAI, reconnu pour ses performances générales et sa capacité à comprendre des textes juridiques en français. Avec 128 000 tokens de contexte, il offre une large capacité. Néanmoins, son coût (5 \$ / 1M tokens en entrée, 15 \$ en sortie) et l'hébergement exclusif sur les serveurs américains d'OpenAI constituent des freins significatifs pour des PME soucieuses de maîtriser leurs dépenses et de respecter la réglementation sur les données.

Llama 3 8B (Meta AI)

Alternative open-source de Meta, utilisable gratuitement en local. Malgré ses 8 milliards de paramètres, ses performances en français restent limitées par rapport à Mistral, et sa fenêtre de contexte de 8 000 tokens se révèle contraignante pour des documents juridiques longs. Un déploiement local nécessite environ 8 Go de VRAM GPU, ce qui représente un investissement matériel non négligeable pour une PME.

3. Tableau comparatif

Critère	mistral-small-latest	Gemini 1.5 Pro	GPT-4o	Llama 3 8B
Origine	France (open-source)	Google (propriétaire)	OpenAI (propriétaire)	Meta (open-source)
Paramètres	Non divulgué	Confidentiel	Confidentiel (~1 T)	8 milliards
Fenêtre contexte	32 000 tokens	1 000 000 tokens	128 000 tokens	8 000 tokens
Français (qualité)	Excellent	Très bon	Très bon	Moyen
Jargon juridique	Excellent	Bon	Bon	Limité
Coût API	0,20 \$ / 1M tokens	3,50 \$ / 1M tokens	5 \$ / 1M tokens	Gratuit (local)
Déploiement local	Non (API Mistral)	Non	Non	Oui
Conformité RGPD	Bonne (EU/RGPD)	Partielle	Partielle	Totale (local)
Licence	Propriétaire (API)	Propriétaire	Propriétaire	Meta Custom

Tableau 1 — Comparaison des modèles sur les critères clés du projet

4. Justification du choix de Mistral pour notre projet

Au regard des critères analysés, **mistral-small-latest constitue le meilleur compromis** pour un chatbot juridique destiné aux PME africaines francophones. Les raisons sont les suivantes :

- **Maîtrise du français juridique** : entraîné sur de larges corpus français (dont des textes légaux), Mistral comprend les tournures du droit OHADA et du droit du travail sénégalais. Lors de nos tests, le modèle a correctement interprété des notions telles que *licenciement abusif*, *acte uniforme relatif au droit commercial général* ou *convention collective sectorielle*.
- **Coût maîtrisé** : à 0,20 \$ pour 1 million de tokens en entrée, mistral-small-latest est économiquement accessible pour une PME — soit 25 fois moins cher que GPT-4o et 17 fois moins cher que Gemini 1.5 Pro.
- **Conformité RGPD** : l'infrastructure de Mistral AI est hébergée en Europe, garantissant que les données juridiques sensibles des PME (contrats, contentieux) restent soumises au droit européen, contrairement aux solutions américaines.
- **Intégration LangChain** : mistral-small-latest est nativement supporté dans LangChain via *ChatMistralAI*, ce qui simplifie le pipeline RAG (retrieve → LLM → réponse) et réduit le temps de développement.
- **Éditeur européen & pérennité** : Mistral AI, startup française fondée en 2023, propose une API stable avec des mises à jour continues. Le suffixe *latest* garantit l'accès automatique aux améliorations futures sans modifier le code.

Conclusion : mistral-small-latest a été retenu comme LLM du projet. Sa combinaison unique de performance en français, de coût minimal (0,20 \$ / 1M tokens) et d'hébergement européen conforme au RGPD en fait le modèle le plus adapté à notre chatbot d'assistance juridique pour les PME opérant sous le droit OHADA et le droit du travail francophone.